

ALGORITMOS GENÉTICOS E REDES NEURAIS

APRENDIZADO NÃO SUPERVISIONADO EM REDES NEURAIS: MAPAS AUTO- ORGANIZÁVEIS (SOM)

Prof. Flávio Belizário da Silva Mota
Universidade do Vale do Sapucaí – UNIVAS
Sistemas de Informação

APRENDIZADO SUPERVISIONADO VS. NÃO SUPERVISIONADO

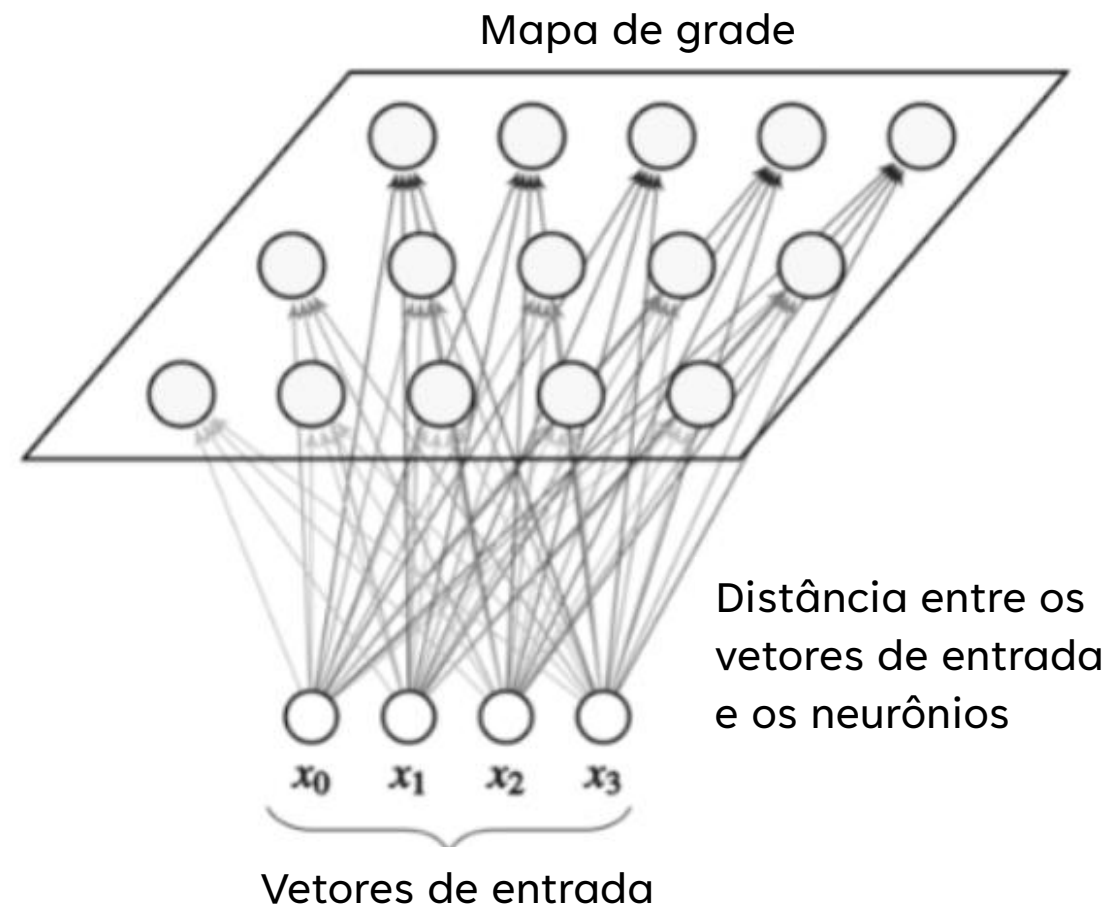
- No aprendizado supervisionado, as Redes Neurais tem como objetivo encontrar uma classe ou um valor contínuo para uma amostra de dados.
- No aprendizado não supervisionado os dados não possuem rótulos. Sendo assim, o objetivo da Rede Neural é decifrar a estrutura do dado.
 - Geralmente é usado para segmentação de clientes, compressão de imagens, agrupamento de objetos.

OS SELF-ORGANIZING MAPS (SOM)

- Os Mapas Auto-Organizáveis foram propostos por Teuvo Kohonen em 1982, com o objetivo de projetar dados de alta dimensão em uma projeção 2D, preservando relações de similaridade.
- Tem como propósito **agrupar** dados de entrada em diversos grupos (*clusters*).
- Utiliza uma estrutura de grade para dispor os neurônios, empregando uma estratégia de aprendizagem chamada o **vencedor-leva-tudo**. Essa abordagem parte do pressuposto que apenas um neurônio fornece a saída da rede em resposta a uma entrada: o neurônio que tiver o maior nível de ativação.


ESTRUTURA DO SOM

- O SOM é composto por neurônios dispostos em uma grade 2D (10x10, por exemplo)
- Cada neurônio possui um vetor de pesos $w_i = [w_{i1}, w_{i2}, \dots, w_{in}]$
- Esses pesos representam “protótipos” dos dados de entrada.



TREINAMENTO DE UM SOM

- Todos os pesos dos neurônios são inicializados aleatoriamente.
- Um vetor de entrada é apresentado ao mapa.
- Os pesos são utilizados para se determinar a distância entre o vetor de entrada e os neurônios.
- O neurônio mais próximo é o vencedor, chamado de BMU (Best Matching Unit).
- Os pesos do BMU e dos seus vizinhos são atualizados para se aproximar do vetor de entrada.



PASSO A PASSO

- Vamos considerar os seguintes neurônios e seus pesos:
- E o seguinte vetor de entrada

$$w_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad w_2 = \begin{bmatrix} 5 \\ 8 \\ -3 \end{bmatrix}$$

$$x = \begin{bmatrix} 3 \\ -1 \\ 2 \end{bmatrix}$$

- A distância entre o vetor de entrada e os neurônios é calculada usando a distância Euclidiana:
- Sendo assim:

$$d_i = \sqrt{\sum_{j=1}^n (w_{ij} - x_j)^2}$$

$$d_1 = \sqrt{(1 - 3)^2 + (2 + 1)^2 + (-1 - 2)^2} \sim 4$$

$$d_2 = \sqrt{(5 - 3)^2 + (8 + 1)^2 + (-3 - 2)^2} \sim 10$$

A distância do neurônio 1 é menor, então ele vence (BMU)

PASSO A PASSO

- Os pesos do BMU são atualizados utilizando:

$$w_{ij} \leftarrow w_{ij} + \alpha(x_j - w_{ij})$$

Onde:

α é a taxa de aprendizado da rede

- Se considerarmos uma taxa de aprendizado de 0,3, o ajuste fica:


$$w_{11} = 1 + 0,3(3 - 1) = 1,6$$

$$w_{12} = 2 + 0,3(-1 - 2) = 1,1$$

$$w_{13} = -1 + 0,3(2 + 1) = -0,1$$


TREINAMENTO DE UM SOM

- Além de atualizar o BMU, uma vizinhança de neurônios é atualizada em um raio, indicando que, com o tempo, neurônios vizinhos passam a representar entradas semelhantes.
- Tipicamente esse raio decresce ao longo do tempo, bem como a taxa de aprendizado.



VISUALIZAÇÃO: U-MATRIX

- A *Unified Distance Matrix* mostra as distâncias médias entre neurônios vizinhos.
- Regiões escuras representam fronteiras entre clusters.
- Regiões claras representam áreas homogêneas.



VANTAGENS E LIMITAÇÕES

- Vantagens:
 - Preserva topologia e relações de vizinhança.
 - Boa ferramenta de visualização e exploração de dados.
- Limitações
 - Difícil definir o tamanho ideal do mapa.
 - Resultados dependem de inicialização e parâmetros de treinamento.

